

Семестровое расчетное задание по методам машинного обучения

Тема: прогноз задержки вылета с экономической оценкой

Бизнес-кейс: авиапредприятие хочет заранее выделять рейсы с высоким риском задержки 15+ минут, чтобы перераспределять наземные ресурсы, проверять оборот борта, гейт, экипаж и обслуживание до возникновения критической задержки.

Тип задачи: основная задача - бинарная классификация задержки 15+ минут; дополнительная задача - регрессия задержки в минутах.

Инструменты: Python, scikit-learn, pandas, matplotlib; параллельная базовая проверка подготовлена в R.

Ключевой результат: лучшая модель по ROC-AUC ранжирует рейсы по риску; топ-20% рейсов по риску покрывают значимую долю фактических задержек и дают положительный расчетный экономический эффект.

Показатель	Значение
Наблюдений после очистки	5 200
Удалено дублей	45
Доля задержек 15+ минут	28.6%
Средняя задержка	10.5 мин
Лучшая классификационная модель	Logistic Regression
ROC-AUC лучшей модели	0.846
Оценочный годовой net benefit	\$416 001

1. Постановка задачи и данные

Выбран вариант задания: прогноз задержки вылета с экономической оценкой. Для авиапредприятия задержка рейса является не только операционной проблемой, но и финансовым риском: растут расходы на наземное обслуживание, компенсации, переработки персонала, цепные задержки последующих рейсов и ухудшается клиентский опыт.

Данные сгенерированы синтетически, потому что учебное задание допускает синтетические данные с реалистичными корреляциями. Это делает проект полностью воспроизводимым на другом компьютере и не требует доступа к закрытым данным авиакомпании.


Целевая переменная для классификации - `delayed_15`: 1, если задержка вылета составляет 15 минут и более. Для дополнительной регрессионной проверки используется `dep_delay_min`: фактическая задержка вылета в минутах.

Переменная	Тип	Описание
<code>scheduled_departure_hour</code>	numeric	Плановый час вылета
<code>load_factor</code>	numeric	Загрузка борта, доля занятых кресел
<code>weather_score</code>	numeric	Индекс сложности погоды от 0 до 1
<code>airport_congestion_index</code>	numeric	Индекс загруженности аэропорта от 0 до 1
<code>previous_arrival_delay_min</code>	numeric	Задержка прибытия предыдущего рейса данного борта, мин
<code>turnaround_buffer_min</code>	numeric	Буфер оборота относительно минимума, мин
<code>dep_delay_min</code>	target_regression	Фактическая задержка вылета, мин
<code>delayed_15</code>	target_classification	1, если задержка вылета 15+ минут, иначе 0

2. Предобработка и EDA

На этапе очистки удалены дубли рейсов, пропуски числовых признаков заполнены медианами, категориальные признаки приведены к единому формату. Для временной корректности данные разделены по дате: первые 80% наблюдений используются для обучения, последние 20% - для теста.

Распределение задержек имеет правый хвост: большинство рейсов вылетает без существенной задержки, но есть рейсы с крупными операционными отклонениями. Такой профиль типичен для задач управления задержками.




Пиковые часы показывают более высокий риск задержек, что соответствует бизнес-логике: нагрузка на гейты, экипажи, буксировщики и службы аэропорта возрастает одновременно.




3. Экономические и операционные закономерности

Сложность погоды и загруженность аэропорта являются важными факторами риска. Также существенное влияние оказывает каскадная задержка: если предыдущий рейс данного борта прибыл поздно, следующий вылет часто получает меньший фактический буфер оборота.




Корреляционная матрица показывает ожидаемые связи: задержка положительно связана с предыдущей задержкой борта, погодой и загруженностью аэропорта; буфер оборота борта действует как защитный фактор.



4. Моделирование

Для классификации задержки 15+ минут сравнивались четыре модели: логистическая регрессия, дерево решений, случайный лес и градиентный бустинг. Логистическая регрессия нужна как интерпретируемый baseline, дерево решений - как простая нелинейная модель, ансамбли - как более гибкие модели для сложных взаимодействий.

Модель	ROC-AUC	F1	Precision	Recall	Accuracy	TS CV ROC-AUC
Logistic Regression	0.846	0.629	0.533	0.768	0.753	0.813
Gradient Boosting	0.841	0.623	0.733	0.542	0.821	0.801
Random Forest	0.836	0.624	0.564	0.697	0.770	0.799
Decision Tree	0.781	0.585	0.505	0.694	0.731	0.740




Для дополнительной регрессионной оценки сравнивались MAE, RMSE, MAPE и R^2 . MAE удобно интерпретировать бизнес-языком: средняя ошибка прогноза в минутах задержки.

Модель	MAE, мин	RMSE, мин	MAPE+1, %	R^2
Gradient Boosting	7.17	10.36	249.6	0.408
Linear Regression	7.18	10.37	252.5	0.406
Random Forest	7.39	10.50	260.1	0.392
Decision Tree	8.25	11.35	301.6	0.289

5. Интерпретация результатов


Для бизнес-задачи важна не только точность, но и объяснимость. Поэтому рассчитана permutation importance: измеряется, насколько падает качество модели, если перемешать конкретный признак. Чем сильнее падение качества, тем важнее признак.

Место	Признак	Важность
1	previous_arrival_delay_min	0.1241
2	weather_score	0.0372
3	is_peak_hour	0.0136
4	turnaround_buffer_min	0.0135
5	load_factor	0.0135
6	airport_congestion_index	0.0127
7	seats	0.0105
8	is_holiday_period	0.0101



Partial dependence показывает направление влияния признаков: риск задержки возрастает при росте задержки предыдущего рейса, ухудшении погоды и увеличении загруженности аэропорта. Рост буфера оборота борта, наоборот, снижает риск.

Partial Dependence: влияние ключевых признаков на риск задержки




6. Экономическая оценка

Модель используется не как автоматическое решение, а как ранний сигнал для операционной службы. Практический сценарий: каждый день отбирать верхние 20% рейсов по риску задержки и заранее проверять ресурсы: гейт, борт, экипаж, наземное обслуживание, буксировку, топливо и оборот.

В расчете принято: 1 час задержки стоит авиапредприятию около \$7 500, то есть \$125 за минуту. Если превентивные действия сокращают задержку на 10 минут для реально проблемного рейса, а проверка одного рейса стоит \$120, можно оценить net benefit.

Показатель	Значение
Тестовых рейсов	1 040
Фактических задержек 15+ мин на тесте	284
Рейсов в топ-20% риска	208
Реальных задержек среди отобранных	154
Доля пойманных задержек	54.2%
Потенциальная экономия на тесте	\$192 500
Стоимость превентивных действий	\$24 960
Net benefit на тестовом периоде	\$167 540
Оценка годового net benefit	\$416 001



Главная бизнес-интерпретация: модель не обязана предсказывать каждую задержку идеально. Достаточно качественно ранжировать рейсы по риску, чтобы операционная команда концентрировалась на наиболее проблемных рейсах.

7. Ограничения и план внедрения

Ограничения модели:

- Используются синтетические данные, поэтому перед промышленным применением модель нужно переобучить на реальной истории рейсов.
- Модель не учитывает форс-мажоры: закрытие воздушного пространства, внезапные технические неисправности, забастовки, массовые сбои IT-систем.
- Экономический эффект рассчитан сценарно; фактическая экономия зависит от того, какие именно действия сможет выполнить операционная служба.
- При внедрении необходимо регулярно проверять drift данных: сезонность, изменение расписания, новых подрядчиков и изменение аэропортовых процессов.

План внедрения:

- Подключить реальные источники: расписание, фактическое время прилета/вылета, погоду, назначение гейта, данные по обороту борта.
- Запускать модель за 2-6 часов до вылета и обновлять риск при появлении новых данных.
- Передавать топ рейсов по риску диспетчеру или руководителю смены.
- Собирать обратную связь: какие превентивные действия выполнены и сколько минут задержки удалось избежать.
- Ежемесячно переобучать модель и сравнивать экономический эффект с базовым сценарием.

Вывод: проект отвечает на главный бизнес-вопрос задания - как ML помогает авиакомпании снизить риски и расходы. Модель дает понятный операционный список рейсов повышенного риска и переводит технические метрики в деньги.

8. Воспроизводимость и структура передачи

Проект подготовлен так, чтобы его можно было передать другому человеку. В архив входят данные, код, ноутбук, R-часть, PDF-отчет, презентация, requirements.txt, environment.yml и скрипты запуска для Windows/macOS/Linux.

Файл/папка	Назначение
data/	Данные и словарь переменных
scripts/run_all.py	Полный запуск проекта одной командой
notebooks/aviation_delay_ml_analysis.ipynb	Jupyter Notebook
r/	Параллельная базовая реализация в R
reports/final_report.pdf	Итоговый отчет 5-10 страниц
presentation/defense_presentation.pptx	Презентация для защиты
requirements.txt	Python-зависимости
run_all.bat	Запуск на Windows

Команда ручного запуска:

```
python -m pip install -r requirements.txt  
python scripts/run_all.py
```